



UNIVERSIDAD NACIONAL AUTÓNOMA DE MÉXICO

FACULTAD DE ESTUDIOS SUPERIORES ACATLÁN

Matemáticas Aplicadas y Computación

Bases de Datos Distribuidas

Proyecto Final

Diseño centralizado y distribuido de la ENOE/ENOEN

PRESENTAN

Alcantara Alviso Isaac
Almaraz Mavil Ernesto
Alvarado Martínez Miguel Eduardo
Vargas Nicolas Gabriel

PROFESOR

Rosas Hernández Javier

UNAM
ACATLÁN

1. Introducción

El objetivo de este proyecto fue diseñar una base de datos centralizada a partir de la Encuesta Nacional de Ocupación y Empleo (ENOE/ENOEN), normalizarla a tercera forma normal y, posteriormente, construir un esquema distribuido mediante fragmentación horizontal. El trabajo se realizó con un enfoque práctico: primero se analizó la estructura histórica de los archivos, después se definió un modelo estable para cargar la información, se implementó la base centralizada, se diseñó la distribución por periodos y finalmente se validó que los fragmentos conservaran la misma información que la base central.

Se trabajó con los periodos comprendidos entre 2020 3T y 2025 4T. El primer trimestre de 2020 no se incluyó porque su estructura presenta más diferencias respecto al resto del histórico, lo que complicaba la integración homogénea de variables.

2. Fuente de datos y criterio de selección

La fuente de información utilizada fue la ENOE/ENOEN para población de 15 años y más. Del histórico disponible se seleccionaron los periodos 2020 3T, 2020 4T y todos los trimestres de 2021 a 2025. Esta selección permitió trabajar con más de cinco años de información y, al mismo tiempo, mantener una estructura relativamente estable entre periodos.

Para el diseño final no se usaron todas las columnas originales. Primero se comparó la estructura de las familias viv, hog, sdem, coe1 y coe2 en todos los periodos. A partir de ese análisis se eligió un núcleo común de variables homogéneas, especialmente de viv, hog y sdem, ya que los módulos coe1 y coe2 presentaron más variaciones entre años y trimestres.

3. Análisis de estructura de los archivos

El análisis de encabezados mostró que viv, hog y sdem conservan una base más homogénea que coe1 y coe2. Por esa razón, las variables demográficas y laborales comparables se concentraron en la tabla persona. El siguiente resumen sintetiza la decisión metodológica tomada.

Familia	Comportamiento observado	Decisión
viv	Muy estable; variaciones menores en columnas geográficas	Usar como base de identificación de vivienda
hog	Estable; pequeñas variaciones entre años	Usar como nivel intermedio entre vivienda y persona
sdem	Muy estable; concentra variables demográficas y laborales comparables	Usar como fuente principal de persona
coe1	Variaciones importantes entre 1T y 2T-4T	Analizado, pero no tomado como núcleo principal
coe2	Variaciones importantes entre años y trimestres	Analizado, pero no tomado como núcleo principal

La comparación de estructuras se realizó con un script que recorrió todos los ZIP del proyecto, leyó los encabezados de los archivos principales y generó un reporte con columnas comunes y variables no homogéneas. Con ello se justificó la exclusión de 2020 1T y la elección del núcleo común.

```
PS C:\Users\e.almazmavil\OneDrive - LEDVANCE GmbH\Documents\PROYECTO_ENOE> python 03_analizar_estructura_enoe.py
Análisis terminado correctamente.
Se generó el archivo:
C:\Users\e.almazmavil\OneDrive - LEDVANCE GmbH\Documents\PROYECTO_ENOE\reporte_columnas_enoe.txt
PS C:\Users\e.almazmavil\OneDrive - LEDVANCE GmbH\Documents\PROYECTO_ENOE> 
```

Figura 1. Ejecución del script de análisis de estructura.




Figura 2. Archivos utilizados dentro de la carpeta del proyecto.

4. Diseño centralizado (OLTP, E/R y 3FN)

El diseño centralizado se planteó con enfoque OLTP, es decir, con tablas relacionadas que representan unidades de información concretas y evitan redundancias innecesarias. El modelo final quedó integrado por las tablas periodo, vivienda, hogar y persona.




Figura 3. Modelo entidad–relación del proyecto ENOE.


4.1 Tablas en tercera forma normal

Tabla	Llave primaria	Atributos principales	Justificación 3FN
periodo	id_periodo	anio, trimestre	Cada atributo depende únicamente de la clave del periodo.
vivienda	id_vivienda	id_periodo, cd_a, con, upm, d_sem, n_pro_viv, v_sel, est, t_loc_tri, t_loc_men, tipo, ur	Se guardan solo atributos propios de la vivienda y su vínculo con el periodo.
hogar	id_hogar	id_vivienda, n_hog, h_mud, d_anio, d_mes, d_dia, p_anio, p_mes, p_dia, r_def, r_pre	Los atributos dependen del hogar y no repiten información de vivienda.
persona	id_persona	id_hogar, n_ent, per, n_ren, sex, eda, niv_ins, ing7c, ingocup, hrsocup, rama, pos_ocu, seg_soc, sub_o, busqueda, clase1, clase2, clase3, emple7c, emp_ppal, dispo, pnea_est, zona	Se concentran las variables demográficas y laborales homogéneas de la persona.

En esta propuesta no se separaron coe1 y coe2 como tablas propias del modelo final porque el análisis histórico mostró demasiadas diferencias entre periodos. Sin embargo, sí se consideraron metodológicamente y sirvieron para justificar que sdem era la fuente más estable para construir una base histórica comparable.

5. Implementación de la base centralizada


Una vez definido el modelo, se creó la base enoe_central.db mediante un script en Python y SQLite. La estructura física retomó las cuatro tablas finales del diseño y dejó listas las llaves primarias y foráneas para soportar la carga histórica.



```
04_crear_bd_final.py > ...
81     rama TEXT,
82     pos_ocu TEXT,
83     seg_soc TEXT,
84     sub_o TEXT,
85     busqueda TEXT,
86     clase1 TEXT,
87     clase2 TEXT,
88     clase3 TEXT,
89     emple7c TEXT,
90     emp_ppal TEXT,
91     dispo TEXT,
92     pnea_est TEXT,
93     zona TEXT,
94     FOREIGN KEY (id_hogar) REFERENCES hogar(id_hogar),
95     UNIQUE(id_hogar, n_ent, per, n_ren)
96 );
97 """
98

PROBLEMS  OUTPUT  DEBUG CONSOLE  TERMINAL  PORTS
C:\Users\e.almazmavil\OneDrive - LEDVANCE GmbH\Documents\PROYECTO_ENOE\reporte_columnas_enoe.txt
PS C:\Users\e.almazmavil\OneDrive - LEDVANCE GmbH\Documents\PROYECTO_ENOE> python 03_analizar_estructura_enoe.py
Análisis terminado correctamente.
Se generó el archivo:
C:\Users\e.almazmavil\OneDrive - LEDVANCE GmbH\Documents\PROYECTO_ENOE\reporte_columnas_enoe.txt
PS C:\Users\e.almazmavil\OneDrive - LEDVANCE GmbH\Documents\PROYECTO_ENOE> python 04_crear_bd_final.py
Base central final creada correctamente:
C:\Users\e.almazmavil\OneDrive - LEDVANCE GmbH\Documents\PROYECTO_ENOE\enoe_central.db
PS C:\Users\e.almazmavil\OneDrive - LEDVANCE GmbH\Documents\PROYECTO_ENOE>
```

Figura 4. Script 04_crear_bd_final.py con la definición del esquema.



```
PS C:\Users\e.almazmavil\OneDrive - LEDVANCE GmbH\Documents\PROYECTO_ENOE> python 04_crear_bd_final.py
Base central final creada correctamente:
C:\Users\e.almazmavil\OneDrive - LEDVANCE GmbH\Documents\PROYECTO_ENOE\enoe_central.db
PS C:\Users\e.almazmavil\OneDrive - LEDVANCE GmbH\Documents\PROYECTO_ENOE>
```

Figura 5. Creación de la base central enoe_central.db.

6. Carga histórica del conjunto de datos

Posteriormente se desarrolló un script de carga que recorrió los archivos ZIP del proyecto, excluyó 2020 1T, detectó automáticamente el año y trimestre de cada archivo y extrajo la información principal de viv, hog y sdem para poblar las tablas periodo, vivienda, hogar y persona.

```
03_analizar_estructura_enoe.py  reporte_columnas_enoe.txt  04_crear_bd_final.py  05_cargar_historico_enoe.py X
05_cargar_historico_enoe.py > ...
297     print(f" Hogares procesados: {total_hog}")
298     print(f" Personas procesadas: {total_per}")
299
300 # -----
301 # VALIDACIÓN FINAL
302 # -----
303 print("\nResumen final de carga:")
304
305 cursor.execute("SELECT COUNT(*) FROM periodo;")
306 print("Periodos cargados: ", cursor.fetchone()[0])
307
308 cursor.execute("SELECT COUNT(*) FROM vivienda;")
309 print("Viviendas cargadas:", cursor.fetchone()[0])
310

PROBLEMS  OUTPUT  DEBUG CONSOLE  TERMINAL  PORTS
python3.13 + v  [icon] [icon] [icon]

PS C:\Users\e.almazmavil\OneDrive - LEDVANCE GmbH\Documents\PROYECTO_ENOE> python 05_cargar_historico_enoe.py
Archivos ZIP encontrados: 22

Procesando conjunto_de_datos_enoe_2023_1t_csv.zip -> 2023 T1
Viviendas procesadas: 150566
Hogares procesados: 151368
Personas procesadas: 450263

Procesando conjunto_de_datos_enoe_2023_2t_csv.zip -> 2023 T2
Viviendas procesadas: 150549
Hogares procesados: 151329
Personas procesadas: 431149

Procesando conjunto_de_datos_enoe_2023_3t_csv.zip -> 2023 T3
Viviendas procesadas: 150496
Hogares procesados: 151286
Personas procesadas: 429077

Procesando conjunto_de_datos_enoe_2023_4t_csv.zip -> 2023 T4
```

Figura 6. Script 05_cargar_historico_enoe.py y comienzo de la carga.

```
PS C:\Users\e.almazmavil\OneDrive - LEDVANCE GmbH\Documents\PROYECTO_ENOE> python 05_cargar_historico_enoe.py
Archivos ZIP encontrados: 22

Procesando conjunto_de_datos_enoe_2023_1t_csv.zip -> 2023 T1
Viviendas procesadas: 150566
Hogares procesados: 151368
Personas procesadas: 450263

Procesando conjunto_de_datos_enoe_2023_2t_csv.zip -> 2023 T2
Viviendas procesadas: 150549
Hogares procesados: 151329
Personas procesadas: 431149

Procesando conjunto_de_datos_enoe_2023_3t_csv.zip -> 2023 T3
Viviendas procesadas: 150496
Hogares procesados: 151286
Personas procesadas: 429077

Procesando conjunto_de_datos_enoe_2023_4t_csv.zip -> 2023 T4
Viviendas procesadas: 150470
Hogares procesados: 151300
Personas procesadas: 419983

Procesando conjunto_de_datos_enoe_2024_1t_csv.zip -> 2024 T1
Viviendas procesadas: 150460
Hogares procesados: 151332
Personas procesadas: 423866

Procesando conjunto_de_datos_enoe_2024_2t_csv.zip -> 2024 T2
Viviendas procesadas: 150577
Hogares procesados: 151452
Personas procesadas: 427123
```

Figura 7. Procesamiento de periodos 2023 y 2024.

```

Procesando conjunto_de_datos_enoe_2024_3t_csv.zip -> 2024 T3
Viviendas procesadas: 150785
Hogares procesados: 151676
Personas procesadas: 423118

Procesando conjunto_de_datos_enoe_2024_4t_csv.zip -> 2024 T4
Viviendas procesadas: 150652
Hogares procesados: 151653
Personas procesadas: 422408

Procesando conjunto_de_datos_enoe_2025_1t_csv.zip -> 2025 T1
Viviendas procesadas: 150522
Hogares procesados: 151570
Personas procesadas: 423302

Procesando conjunto_de_datos_enoe_2025_2t_csv.zip -> 2025 T2
Viviendas procesadas: 150442
Hogares procesados: 151468
Personas procesadas: 423744

Procesando conjunto_de_datos_enoe_2025_3t_csv.zip -> 2025 T3
Viviendas procesadas: 150405
Hogares procesados: 151354
Personas procesadas: 422306

Procesando conjunto_de_datos_enoe_2025_4t_csv.zip -> 2025 T4
Viviendas procesadas: 150356
Hogares procesados: 151333
Personas procesadas: 419038

Procesando conjunto_de_datos_enoen_2020_3t_csv.zip -> 2020 T3
Viviendas procesadas: 160998
Hogares procesados: 161806
Personas procesadas: 296874

```

Figura 8. Procesamiento de 2024 y 2025.

```

Procesando conjunto_de_datos_enoen_2020_4t_csv.zip -> 2020 T4
Viviendas procesadas: 160353
Hogares procesados: 161220
Personas procesadas: 356790

Procesando conjunto_de_datos_enoen_2021_1t_csv.zip -> 2021 T1
Viviendas procesadas: 146323
Hogares procesados: 147103
Personas procesadas: 350728

Procesando conjunto_de_datos_enoen_2021_2t_csv.zip -> 2021 T2
Viviendas procesadas: 143741
Hogares procesados: 144505
Personas procesadas: 381319

Procesando conjunto_de_datos_enoen_2021_3t_csv.zip -> 2021 T3
Viviendas procesadas: 151689
Hogares procesados: 152608
Personas procesadas: 428160

Procesando conjunto_de_datos_enoen_2021_4t_csv.zip -> 2021 T4
Viviendas procesadas: 151645
Hogares procesados: 152538
Personas procesadas: 434826

Procesando conjunto_de_datos_enoen_2022_1t_csv.zip -> 2022 T1
Viviendas procesadas: 151652
Hogares procesados: 122125
Personas procesadas: 326055

Procesando conjunto_de_datos_enoen_2022_2t_csv.zip -> 2022 T2
Viviendas procesadas: 151646
Hogares procesados: 152464
Personas procesadas: 405959

```

Figura 9. Procesamiento de 2020 y 2021.

```
Procesando conjunto_de_datos_enoen_2022_3t_csv.zip -> 2022 T3
```

```
Viviendas procesadas: 132391
```

```
Hogares procesados: 133141
```

```
Personas procesadas: 398591
```

```
Procesando conjunto_de_datos_enoen_2022_4t_csv.zip -> 2022 T4
```

```
Viviendas procesadas: 132410
```

```
Hogares procesados: 133108
```

```
Personas procesadas: 396629
```

```
Resumen final de carga:
```

```
Periodos cargados: 22
```

```
Viviendas cargadas: 3289097
```

```
Hogares cargados: 3277707
```

```
Personas cargadas: 8891308
```

```
Carga histórica completada correctamente.
```

```
PS C:\Users\e.almazmavil\OneDrive - LEDVANCE GmbH\Documents\PROYECTO_ENOE> █
```

Figura 10. Resumen final de la carga histórica.

Al finalizar la carga se obtuvieron 22 periodos, 3,289,097 viviendas, 3,277,707 hogares y 8,891,308 personas. Estos valores sirvieron como base para las consultas centralizadas y para la fragmentación posterior.

7. Consultas centralizadas

Con la base centralizada cargada se realizaron cinco consultas principales: total de personas por periodo, total de personas por sexo y periodo, promedio de edad por sexo y periodo, distribución por nivel educativo y promedio de ingreso y horas ocupadas por periodo.

```
PS C:\Users\e.almazmavil\OneDrive - LEDVANCE GmbH\Documents\PROYECTO_ENOE> python 06_consultas_centralizadas.py
```

```
CONSULTA 1: Total de personas por año y trimestre
```

	año	trimestre	total_personas
0	2020	3	296874
1	2020	4	356790
2	2021	1	350728
3	2021	2	381319
4	2021	3	428160
5	2021	4	434826
6	2022	1	326055
7	2022	2	405959
8	2022	3	398591
9	2022	4	396629
10	2023	1	450263
11	2023	2	431149
12	2023	3	429077
13	2023	4	419983
14	2024	1	423866
15	2024	2	427123
16	2024	3	423118
17	2024	4	422408
18	2025	1	423302
19	2025	2	423744
20	2025	3	422306
21	2025	4	419038

Figura 11. Consulta 1: total de personas por año y trimestre.

```
CONSULTA 2: Total de personas por sexo y periodo
  anio  trimestre  sex  total_personas
0  2020           3      5415
1  2020           3    1  140962
2  2020           3    2  150497
3  2020           4    6401
4  2020           4    1  169200
..     ...       ...  ..      ...
61  2025           3    1  197333
62  2025           3    2  215099
63  2025           4   10065
64  2025           4    1  195755
65  2025           4    2  213218

[66 rows x 4 columns]
```

Figura 12. Consulta 2: total de personas por sexo y periodo.

CONSULTA 3: Promedio de edad por sexo y periodo				
	anio	trimestre	sex	edad_promedio
0	2020	3	1	32.47
1	2020	3	2	34.42
2	2020	4	1	32.59
3	2020	4	2	34.58
4	2021	1	1	32.57
5	2021	1	2	34.51
6	2021	2	1	32.65
7	2021	2	2	34.64
8	2021	3	1	32.64
9	2021	3	2	34.57
10	2021	4	1	32.74
11	2021	4	2	34.71
12	2022	1	1	32.89
13	2022	1	2	34.92
14	2022	2	1	32.89
15	2022	2	2	34.92
16	2022	3	1	32.99
17	2022	3	2	35.05
18	2022	4	1	33.04
19	2022	4	2	35.14
20	2023	1	1	33.16
21	2023	1	2	35.17
22	2023	2	1	33.30
23	2023	2	2	35.38
24	2023	3	1	33.55
25	2023	3	2	35.63
26	2023	4	1	33.65
27	2023	4	2	35.70
28	2024	1	1	33.82
29	2024	1	2	35.91
30	2024	2	1	33.72
31	2024	2	2	35.79
32	2024	3	1	33.78
33	2024	3	2	35.80
34	2024	4	1	33.74
35	2024	4	2	35.69
36	2025	1	1	33.85
37	2025	1	2	35.77
38	2025	2	1	33.85
39	2025	2	2	35.72
40	2025	3	1	34.04
41	2025	3	2	35.98
42	2025	4	1	34.19
43	2025	4	2	36.20

Figura 13. Consulta 3: promedio de edad por sexo y periodo.

CONSULTA 4: Distribución por nivel educativo y periodo

	anio	trimestre	niv_ins	total_personas
0	2020	3	4	87076
1	2020	3	3	77523
2	2020	3	1	59248
3	2020	3	2	48526
4	2020	3	0	24278
..	...	...	...	...
127	2025	4	3	107465
128	2025	4	1	77716
129	2025	4	2	65598
130	2025	4	0	32004
131	2025	4	5	814

[132 rows x 4 columns]

Figura 14. Consulta 4: distribución por nivel educativo y periodo.

CONSULTA 5: Promedio de ingreso y horas ocupadas por periodo

	anio	trimestre	ingreso_promedio	horas_promedio
0	2020	3	2040.63	15.73
1	2020	4	2196.59	17.27
2	2021	1	2291.44	17.07
3	2021	2	2332.17	17.88
4	2021	3	2341.79	17.90
5	2021	4	2375.35	18.40
6	2022	1	2465.10	17.86
7	2022	2	2556.48	18.41
8	2022	3	2565.29	18.60
9	2022	4	2630.73	19.01
10	2023	1	2768.05	18.84
11	2023	2	2777.68	18.43
12	2023	3	2843.55	18.82
13	2023	4	2897.18	18.89
14	2024	1	3068.30	18.63
15	2024	2	3074.71	18.60
16	2024	3	3139.05	18.64
17	2024	4	3050.02	18.61
18	2025	1	2968.07	18.00
19	2025	2	2948.22	18.10
20	2025	3	2973.21	18.34
21	2025	4	3174.58	18.69

PS C:\Users\e.almazmavil\OneDrive - LEDVANCE GmbH\Documents\PROYECTO_ENOE> █

Figura 15. Consulta 5: promedio de ingreso y horas ocupadas por periodo.

8. Diseño de la distribución


El esquema distribuido se diseñó mediante fragmentación horizontal por periodo. Se eligió este criterio porque el análisis es histórico y, por lo tanto, el periodo constituye una dimensión natural para dividir la información sin perder coherencia lógica. Se definieron dos fragmentos: el primero con los años 2020 a 2022 y el segundo con 2023 a 2025.

- Fragmento 1: 2020–2022
- Fragmento 2: 2023–2025
- Base centralizada: 2020 3T a 2025 4T

Esta decisión permite consultas más focalizadas sobre subconjuntos temporales y, al mismo tiempo, mantiene una reconstrucción clara del histórico completo cuando es necesario.

9. Implementación de la fragmentación

Para implementar la distribución se creó un script que generó las bases enoe_frag_1.db y enoe_frag_2.db con la misma estructura que la base centralizada. Después se copiaron los registros correspondientes a cada rango de años y se verificaron los conteos iniciales de ambos fragmentos.



```
04_crear_bd_final.py 05_cargar_historico_enoe.py 06_consultas_centralizadas.py 07_fragmentar_enoe.py X
07_fragmentar_enoe.py > ...
10 def crear_estructura(db_path):
21     id_periodo INTEGER PRIMARY KEY,
22     anio INTEGER NOT NULL,
23     trimestre INTEGER NOT NULL,
24     UNIQUE(anio, trimestre)
25 );
26 """
27
28 cur.execute("""
29 CREATE TABLE vivienda (
30     id_vivienda INTEGER PRIMARY KEY,
31     id_periodo INTEGER NOT NULL,
32     cd_a TEXT,
33     con TEXT,
34     upm TEXT,
35     d_sem TEXT,
36     n_pro_viv TEXT,
37     v_sel TEXT,
38     est TEXT,
39     t_loc_tri TEXT,
40     t_loc_men TEXT,
41     tipo TEXT,
42     ur TEXT,
43     FOREIGN KEY (id_periodo) REFERENCES periodo(id_periodo)
44 );
45 """
46
47 cur.execute("""
48 CREATE TABLE hogar (
49     id_hogar INTEGER PRIMARY KEY,
50     id_vivienda INTEGER NOT NULL,
51     n_hog TEXT
```

Figura 16. Script 07_fragmentar_enoe.py.

```
PS C:\Users\e.almazmavil\OneDrive - LEDVANCE GmbH\Documents\PROYECTO_ENOE> python 07_fragmentar_enoe.py
Fragmentación completada correctamente.

FRAGMENTO 1 (2020-2022)
Periodos : 10
Viviendas: 1482817
Hogares : 1460586
Personas : 3775931

FRAGMENTO 2 (2023-2025)
Periodos : 12
Viviendas: 1806280
Hogares : 1817121
Personas : 5115377
```

Figura 17. Ejecución del script de fragmentación y conteos de los fragmentos.




Figura 18. Archivos de respaldo generados después de la fragmentación.

Figura 18 bis. Resumen visual de la organización de la base central y los fragmentos después de la fragmentación.

Resumen visual de las bases de datos del proyecto ENOE

Vista limpia de la base centralizada y de los dos fragmentos distribuidos.

enoe_central.db

Base centralizada

Periodos incluidos

- 22 periodos
- 2020 3T a 2025 4T

Tablas principales

- periodo
- vivienda
- hogar
- persona

Conteos

periodo	22
vivienda	3,289,097
hogar	3,277,707
persona	8,891,308

Observación

Integra el histórico completo usado en el proyecto.

En el modelo final se destacan 4 tablas principales.

enoe_frag_1.db

Fragmento 1

Periodos incluidos

- 10 periodos
- 2020 3T-4T
- 2021 1T-4T
- 2022 1T-4T

Tablas principales

- periodo
- vivienda
- hogar
- persona

Conteos

periodo	10
vivienda	1,482,817
hogar	1,460,586
persona	3,775,931

Observación

Contiene la parte histórica inicial del esquema distribuido.

Se obtuvo mediante fragmentación horizontal por periodo.

enoe_frag_2.db

Fragmento 2

Periodos incluidos

- 12 periodos
- 2023 1T-4T
- 2024 1T-4T
- 2025 1T-4T

Tablas principales

- periodo
- vivienda
- hogar
- persona

Conteos

periodo	12
vivienda	1,806,280
hogar	1,817,121
persona	5,115,377

Observación

Contiene la parte histórica reciente del esquema distribuido.

Complementa al fragmento 1 y juntos reproducen la base central.

Nota: Para la representación visual del modelo final se destacan las tablas periodo, vivienda, hogar y persona.

Esta vista resume cómo quedó organizada la información entre la base centralizada y los dos fragmentos distribuidos.

10. Consultas equivalentes sobre el esquema distribuido

A continuación se modificaron las cinco consultas centralizadas para ejecutarlas sobre los dos fragmentos. Para reconstruir la información se usó ATTACH DATABASE y UNION ALL, reagregando los resultados cuando fue necesario. El objetivo de este paso fue demostrar que el esquema distribuido puede producir resultados equivalentes al centralizado.

```
PS C:\Users\e.almazmavil\OneDrive - LEDVANCE GmbH\Documents\PROYECTO_ENOE> python 08_consultas_equivalentes.py

CONSULTA EQUIVALENTE 1: Total de personas por año y trimestre
  año  trimestre  total_personas
0  2020           3      296874
1  2020           4      356790
2  2021           1      350728
3  2021           2      381319
4  2021           3      428160
5  2021           4      434826
6  2022           1      326055
7  2022           2      405959
8  2022           3      398591
9  2022           4      396629
10 2023           1      450263
11 2023           2      431149
12 2023           3      429077
13 2023           4      419983
14 2024           1      423866
15 2024           2      427123
16 2024           3      423118
17 2024           4      422408
18 2025           1      423302
19 2025           2      423744
20 2025           3      422306
21 2025           4      419038
```

Figura 19. Consulta equivalente 1.

```
CONSULTA EQUIVALENTE 2: Total de personas por sexo y periodo
  año  trimestre  sex  total_personas
0  2020           3      5415
1  2020           3   1      140962
2  2020           3   2      150497
3  2020           4      6401
4  2020           4   1      169200
..   ...         ...   ..      ...
61 2025           3   1      197333
62 2025           3   2      215099
63 2025           4      10065
64 2025           4   1      195755
65 2025           4   2      213218

[66 rows x 4 columns]
```

Figura 20. Consulta equivalente 2.

CONSULTA EQUIVALENTE 3: Promedio de edad por sexo y periodo

	anio	trimestre	sex	edad_promedio
0	2020	3	1	32.47
1	2020	3	2	34.42
2	2020	4	1	32.59
3	2020	4	2	34.58
4	2021	1	1	32.57
5	2021	1	2	34.51
6	2021	2	1	32.65
7	2021	2	2	34.64
8	2021	3	1	32.64
9	2021	3	2	34.57
10	2021	4	1	32.74
11	2021	4	2	34.71
12	2022	1	1	32.89
13	2022	1	2	34.92
14	2022	2	1	32.89
15	2022	2	2	34.92
16	2022	3	1	32.99
17	2022	3	2	35.05
18	2022	4	1	33.04
19	2022	4	2	35.14
20	2023	1	1	33.16
21	2023	1	2	35.17
22	2023	2	1	33.30
23	2023	2	2	35.38
24	2023	3	1	33.55
25	2023	3	2	35.63
26	2023	4	1	33.65
27	2023	4	2	35.70
28	2024	1	1	33.82
29	2024	1	2	35.91
30	2024	2	1	33.72
31	2024	2	2	35.79
32	2024	3	1	33.78
33	2024	3	2	35.80
34	2024	4	1	33.74
35	2024	4	2	35.69
36	2025	1	1	33.85
37	2025	1	2	35.77
38	2025	2	1	33.85
39	2025	2	2	35.72
40	2025	3	1	34.04
41	2025	3	2	35.98
42	2025	4	1	34.19
43	2025	4	2	36.20

Figura 21. Consulta equivalente 3.

```
CONSULTA EQUIVALENTE 4: Distribución por nivel educativo y periodo
  anio trimestre niv_ins total_personas
0  2020          3      4      87076
1  2020          3      3      77523
2  2020          3      1      59248
3  2020          3      2      48526
4  2020          3      0      24278
..  ...          ...    ...      ...
127 2025          4      3     107465
128 2025          4      1      77716
129 2025          4      2      65598
130 2025          4      0      32004
131 2025          4      5        814

[132 rows x 4 columns]
```

Figura 22. Consulta equivalente 4.

```
CONSULTA EQUIVALENTE 5: Promedio de ingreso y horas ocupadas por periodo
  anio trimestre ingreso_promedio horas_promedio
0  2020          3      2040.63      15.73
1  2020          4      2196.59      17.27
2  2021          1      2291.44      17.07
3  2021          2      2332.17      17.88
4  2021          3      2341.79      17.90
5  2021          4      2375.35      18.40
6  2022          1      2465.10      17.86
7  2022          2      2556.48      18.41
8  2022          3      2565.29      18.60
9  2022          4      2630.73      19.01
10 2023          1      2768.05      18.84
11 2023          2      2777.68      18.43
12 2023          3      2843.55      18.82
13 2023          4      2897.18      18.89
14 2024          1      3068.30      18.63
15 2024          2      3074.71      18.60
16 2024          3      3139.05      18.64
17 2024          4      3050.02      18.61
18 2025          1      2968.07      18.00
19 2025          2      2948.22      18.10
20 2025          3      2973.21      18.34
21 2025          4      3174.58      18.69
PS C:\Users\e.almazmavil\OneDrive - LEDVANCE GmbH\Documents\PROYECTO_ENOE> █
```

Figura 23. Consulta equivalente 5.

11. Consultas distribuidas

Además de las consultas equivalentes, se hicieron cinco consultas distribuidas orientadas a aprovechar el criterio de fragmentación por periodo. Dos de ellas se ejecutaron sobre el fragmento 2020–2022, dos sobre el fragmento 2023–2025 y una más comparó resultados entre ambos fragmentos.

```
CONSULTA DISTRIBUIDA 1: Total de personas por periodo (Fragmento 1)
  anio  trimestre  total_personas
0  2020           3      296874
1  2020           4      356790
2  2021           1      350728
3  2021           2      381319
4  2021           3      428160
5  2021           4      434826
6  2022           1      326055
7  2022           2      405959
8  2022           3      398591
9  2022           4      396629
```

Figura 24. Consulta distribuida 1.

```
CONSULTA DISTRIBUIDA 4: Promedio de edad por sexo (Fragmento 1)
  anio  trimestre  sex  edad_promedio
0  2020           3   1      32.47
1  2020           3   2      34.42
2  2020           4   1      32.59
3  2020           4   2      34.58
4  2021           1   1      32.57
5  2021           1   2      34.51
6  2021           2   1      32.65
7  2021           2   2      34.64
8  2021           3   1      32.64
9  2021           3   2      34.57
10 2021           4   1      32.74
11 2021           4   2      34.71
12 2022           1   1      32.89
13 2022           1   2      34.92
14 2022           2   1      32.89
15 2022           2   2      34.92
16 2022           3   1      32.99
17 2022           3   2      35.05
18 2022           4   1      33.04
19 2022           4   2      35.14
```

Figura 25. Consulta distribuida 4.

CONSULTA DISTRIBUIDA 2: Total de personas por periodo (Fragmento 2)			
	anio	trimestre	total_personas
0	2023	1	450263
1	2023	2	431149
2	2023	3	429077
3	2023	4	419983
4	2024	1	423866
5	2024	2	427123
6	2024	3	423118
7	2024	4	422408
8	2025	1	423302
9	2025	2	423744
10	2025	3	422306
11	2025	4	419038

Figura 26. Consulta distribuida 2.

CONSULTA DISTRIBUIDA 3: Promedio de ingreso por sexo (Fragmento 2)				
	anio	trimestre	sex	ingreso_promedio
0	2023	1		0.00
1	2023	1	1	3801.39
2	2023	1	2	1908.82
3	2023	2		0.00
4	2023	2	1	3806.52
5	2023	2	2	1922.70
6	2023	3		0.00
7	2023	3	1	3890.13
8	2023	3	2	1977.22
9	2023	4		0.00
10	2023	4	1	3951.87
11	2023	4	2	2029.51
12	2024	1		0.00
13	2024	1	1	4202.63
14	2024	1	2	2139.94
15	2024	2		0.00
16	2024	2	1	4195.03
17	2024	2	2	2148.24
18	2024	3		0.00
19	2024	3	1	4282.63
20	2024	3	2	2195.54
21	2024	4		0.00
22	2024	4	1	4170.58
23	2024	4	2	2144.88
24	2025	1		0.00
25	2025	1	1	4088.73
26	2025	1	2	2080.24
27	2025	2		0.00
28	2025	2	1	4043.46
29	2025	2	2	2080.03
30	2025	3		0.00
31	2025	3	1	4069.46
32	2025	3	2	2104.00
33	2025	4		0.00
34	2025	4	1	4337.93
35	2025	4	2	2256.36

Figura 27. Consulta distribuida 3.

```
CONSULTA DISTRIBUIDA 5: Comparación de total de personas por año
  anio  total_personas
0  2020         653664
1  2021        1595033
2  2022        1527234
3  2023        1730472
4  2024        1696515
5  2025        1688390
PS C:\Users\e.almazmavil\OneDrive - LEDVANCE GmbH\Documents\PROYECTO_ENOE>
```

Figura 28. Consulta distribuida 5.

En este bloque se observó que la fragmentación horizontal tiene utilidad cuando el criterio de análisis coincide con el criterio de distribución. Por ejemplo, las consultas locales sobre 2020–2022 o sobre 2023–2025 evitan recorrer la totalidad del histórico.

12. Validación de la distribución

Por último, se validó que la suma de los fragmentos coincidiera exactamente con la base centralizada. Se compararon los conteos de las tablas periodo, vivienda, hogar y persona, se revisaron los periodos contenidos en cada base y se verificó el total de personas por año.

```
PS C:\Users\e.almazmavil\OneDrive - LEDVANCE GmbH\Documents\PROYECTO_ENOE> python 10_validacion_distribucion.py

VALIDACIÓN 1: Totales generales
  tabla  total_central  total_frag1  total_frag2  suma_fragmentos  diferencia
0  periodo           22           10           12           22           0
1  vivienda        3289097        1482817        1806280        3289097           0
2   hogar         3277707        1460586        1817121        3277707           0
3  persona         8891308        3775931        5115377        8891308           0
```

Figura 29. Validación 1: totales generales.

VALIDACIÓN 2: Periodos contenidos en cada base			
	origen	año	trimestre
0	central	2020	3
1	central	2020	4
2	central	2021	1
3	central	2021	2
4	central	2021	3
5	central	2021	4
6	central	2022	1
7	central	2022	2
8	central	2022	3
9	central	2022	4
10	central	2023	1
11	central	2023	2
12	central	2023	3
13	central	2023	4
14	central	2024	1
15	central	2024	2
16	central	2024	3
17	central	2024	4
18	central	2025	1
19	central	2025	2
20	central	2025	3
21	central	2025	4
22	frag1	2020	3
23	frag1	2020	4
24	frag1	2021	1
25	frag1	2021	2
26	frag1	2021	3
27	frag1	2021	4
28	frag1	2022	1
29	frag1	2022	2
30	frag1	2022	3
31	frag1	2022	4
32	frag2	2023	1
33	frag2	2023	2
34	frag2	2023	3
35	frag2	2023	4
36	frag2	2024	1
37	frag2	2024	2
38	frag2	2024	3
39	frag2	2024	4
40	frag2	2025	1
41	frag2	2025	2
42	frag2	2025	3
43	frag2	2025	4

Figura 30. Validación 2: periodos contenidos en cada base.

VALIDACIÓN 3: Personas por año, central vs fragmentos						
	año	central	frag1	frag2	suma_fragmentos	diferencia
0	2020	653664	653664	0	653664	0
1	2021	1595033	1595033	0	1595033	0
2	2022	1527234	1527234	0	1527234	0
3	2023	1730472	0	1730472	1730472	0
4	2024	1696515	0	1696515	1696515	0
5	2025	1688390	0	1688390	1688390	0

PS C:\Users\e.almazmavil\OneDrive - LEDVANCE GmbH\Documents\PROYECTO_ENOE>

Figura 31. Validación 3: personas por año, central vs fragmentos.

Los resultados mostraron diferencia igual a cero en las validaciones principales, por lo que se concluye que la fragmentación preservó la integridad lógica de la base y no provocó pérdida de información.

13. Conclusiones

El proyecto permitió construir un diseño centralizado normalizado y, a partir de él, un esquema distribuido funcional sobre un histórico real de la ENOE/ENOEN. La decisión de trabajar con un núcleo común de variables resultó adecuada, ya que facilitó la integración entre años y trimestres sin perder consistencia. Asimismo, la fragmentación horizontal por periodo resultó una estrategia natural y fácil de justificar, pues el análisis histórico coincide con la forma en que se separó la información.

Las pruebas realizadas muestran que el esquema distribuido puede reproducir los resultados del centralizado mediante consultas equivalentes y, además, permite construir consultas focalizadas sobre subconjuntos del histórico. En consecuencia, puede afirmarse que la base centralizada es más conveniente para consultas globales y administración simple, mientras que la distribuida ofrece ventajas cuando el análisis se concentra en rangos temporales específicos.

14. Ventajas y desventajas

Esquema	Ventajas	Desventajas
Centralizado	Toda la información está en una sola base; las consultas globales son más sencillas; la administración es más directa.	Concentra todo el volumen histórico; las consultas extensas pueden ser más pesadas; no aprovecha la separación natural por periodos.
Distribuido	Permite dividir el histórico en fragmentos más manejables; favorece consultas localizadas; escala mejor para análisis por periodo.	Las consultas globales son más complejas; requiere reconstrucción con UNION ALL; administrar varias bases exige mayor cuidado.

15. Archivos entregados

Como parte del entregable final se consideran los siguientes componentes:

- Trabajo escrito en formato .docx
- Scripts en Python utilizados durante el proyecto
- Respaldo de la base centralizada: enoe_central.db
- Respaldo del fragmento 1: enoe_frag_1.db
- Respaldo del fragmento 2: enoe_frag_2.db

16. Scripts desarrollados

Los scripts completos se entregan por separado como parte del proyecto. En el documento se presenta un resumen de su función para dejar claro el procedimiento seguido.

Script	Propósito
03_analizar_estructura_enoe.py	Comparar encabezados de viv, hog, sdem, coe1 y coe2 para identificar variables homogéneas.
04_crear_bd_final.py	Crear la base centralizada final con las tablas periodo, vivienda, hogar y persona.

05_cargar_historico_enoe.py	Recorrer los ZIP válidos y cargar la información histórica a enoe_central.db.
06_consultas_centralizadas.py	Ejecutar las cinco consultas principales sobre la base centralizada.
07_fragmentar_enoe.py	Crear enoe_frag_1.db y enoe_frag_2.db mediante fragmentación horizontal por periodo.
08_consultas_equivalentes.py	Reescribir las cinco consultas principales para el esquema distribuido.
09_consultas_distribuidas.py	Ejecutar cinco consultas diseñadas específicamente para aprovechar la distribución.
10_validacion_distribucion.py	Comparar central vs fragmentos y verificar que no exista pérdida de información.

17. Migración de SQLite a PostgreSQL para respaldo y revisión

El proyecto original se desarrolló en SQLite porque la computadora de trabajo utilizada presentaba restricciones para instalar software externo y para trabajar con otros gestores de bases de datos. Por esa razón, la construcción de la base centralizada, la fragmentación horizontal y las consultas del proyecto se realizaron inicialmente en archivos .db de SQLite. Sin embargo, para facilitar la revisión del resultado final y también generar respaldos en un gestor más común para entornos académicos y profesionales, se realizó una migración complementaria a PostgreSQL.

La migración no sustituyó el trabajo original, sino que funcionó como una etapa adicional de apoyo para la entrega. El procedimiento consistió en recrear en PostgreSQL las mismas tablas del modelo final (periodo, vivienda, hogar y persona), exportar la información desde SQLite a archivos CSV mediante Python, cargar esos CSV en PostgreSQL y verificar que los conteos coincidieran con los obtenidos en SQLite. De este modo, se logró mantener la integridad del proyecto y, al mismo tiempo, disponer de respaldos más fáciles de consultar por terceros.

17.1 Procedimiento utilizado

El procedimiento para lograr la migración fue el siguiente: primero se creó en PostgreSQL el mismo conjunto de tablas definido en SQLite; después se utilizó un script en Python para exportar cada una de las tablas a formato CSV; posteriormente se importaron esos archivos en pgAdmin, respetando el orden periodo → vivienda → hogar → persona para no romper la dependencia entre llaves foráneas; finalmente se verificó que las tres bases (enoe_central, enoe_frag_1 y enoe_frag_2) conservaran los mismos conteos y la misma división por periodos que en el esquema distribuido original.

```
PS C:\Users\zeroa\OneDrive\Documents\ISAAC\MAC\Proyecto> python exportar.py
Exportando periodo de enoe_central.db...
Exportando vivienda de enoe_central.db...
Exportando hogar de enoe_central.db...
Exportando persona de enoe_central.db...
```

Figura 32. Ejecución del script en Python para exportar las tablas de SQLite a archivos CSV.



```
1 import sqlite3
2 import pandas as pd
3 import os
4
5 BASES = [
6     "enoe_central.db",
7     "enoe_frag_1.db",
8     "enoe_frag_2.db"
9 ]
10
11 TABLAS = ["periodo", "vivienda", "hogar", "persona"]
12
13 for base in BASES:
14     nombre_base = os.path.splitext(base)[0]
15     carpeta_salida = f"csv_{nombre_base}"
16     os.makedirs(carpeta_salida, exist_ok=True)
17
18     conn = sqlite3.connect(base)
19
20     for tabla in TABLAS:
21         print(f"Exportando {tabla} de {base}...")
22         df = pd.read_sql_query(f"SELECT * FROM {tabla}", conn)
23         ruta_csv = os.path.join(carpeta_salida, f"{tabla}.csv")
24         df.to_csv(ruta_csv, index=False, encoding="utf-8")
25
26     conn.close()
27
28 print("Exportación terminada.")
```

Figura 33. Script en Python utilizado para generar los archivos CSV a partir de las bases SQLite.




Figura 34. Carpetas y archivos CSV generados para enoe_central, enoe_frag_1 y enoe_frag_2.




Figura 35. Carga de un archivo CSV en pgAdmin mediante la opción Import/Export Data.




Figura 36. Validación de conteos en PostgreSQL para la base central migrada.




Figura 37. Validación del conteo de la tabla hogar en el fragmento 1 dentro de PostgreSQL.




Figura 38. Validación del conteo de la tabla persona en el fragmento 2 dentro de PostgreSQL.

pgAdmin 4

Object Explorer

- enoe_central
 - enoe_frag_1
 - enoe_frag_2
 - Casts
 - Catalogs
 - Event Triggers
 - Extensions
 - Foreign Data Wrappers
 - Languages
 - Publications
 - Schemas (1)
 - public
 - Aggregates
 - Collations
 - Domains
 - FTS Configurations
 - FTS Dictionaries
 - FTS Parsers
 - FTS Templates
 - Foreign Tables
 - Functions
 - Materialized Views
 - Operators
 - Procedures
 - Sequences
 - Tables (4)
 - hogar
 - periodo

Query

```
SELECT * FROM periodo ORDER BY anio, trimestre;
```

Data Output

	id_perodo [PK] integer	anio integer	trimestre integer
1	13	2020	3
2	14	2020	4
3	15	2021	1
4	16	2021	2
5	17	2021	3
6	18	2021	4
7	19	2022	1
8	20	2022	2
9	21	2022	3
10	22	2022	4

Showing rows: 1 to 10 Page No: 1

Figura 39. Visualización de la tabla periodo en PostgreSQL para verificar la división temporal del fragmento 1.

pgAdmin 4

Object Explorer

- enoe_central
 - enoe_frag_1
 - enoe_frag_2
 - Casts
 - Catalogs
 - Event Triggers
 - Extensions
 - Foreign Data Wrappers
 - Languages
 - Publications
 - Schemas (1)
 - public
 - Aggregates
 - Collations
 - Domains
 - FTS Configurations
 - FTS Dictionaries
 - FTS Parsers
 - FTS Templates
 - Foreign Tables
 - Functions
 - Materialized Views
 - Operators
 - Procedures
 - Sequences
 - Tables (4)
 - hogar
 - periodo
 - persona
 - vivienda
 - Trigger Functions

Query

```
SELECT * FROM periodo ORDER BY anio, trimestre;
```

Data Output

	id_perodo [PK] integer	anio integer	trimestre integer
1	1	2023	1
2	2	2023	2
3	3	2023	3
4	4	2023	4
5	5	2024	1
6	6	2024	2
7	7	2024	3
8	8	2024	4
9	9	2025	1
10	10	2025	2
11	11	2025	3
12	12	2025	4

Showing rows: 1 to 12 Page No: 1

Successfully run. Total query runtime: 1

Figura 40. Visualización de la tabla periodo en PostgreSQL para verificar la división temporal del fragmento 2.

Con esta migración quedó demostrado que el trabajo desarrollado originalmente en SQLite puede revisarse también en PostgreSQL sin alterar la lógica del proyecto. La base centralizada conservó sus 22 periodos y los fragmentos mantuvieron la separación temporal correcta: el fragmento 1 con los años 2020 a 2022 y el fragmento 2 con los años 2023 a 2025. Por ello, la migración sirvió como

apoyo para la revisión y como medio para generar respaldos adicionales en PostgreSQL, mientras que el desarrollo metodológico del proyecto continuó fundamentado en el entorno SQLite que se utilizó desde el inicio.